UNIVERSITÉ PARIS II
PANTHÉON-ASSAS

PROJET IA IN FINANCE

Modélisation du Risque de Crédit

Prédiction du défaut de paiement à partir du dataset **UCI Default of Credit Card Clients** — une tâche de **classification binaire** au service des décisions d'octroi de crédit et du suivi de portefeuille en temps réel.

DONNÉES

Présentation du Dataset

Le dataset UCI contient **30 000 observations** et **24 variables**, organisées en trois grandes familles complémentaires. La variable cible, `default_payment_next_month`, vaut **1** si le client fait défaut le mois suivant, et **0** sinon.

👤 Profil Client

- Limite de crédit (LIMIT_BAL)
- Sexe, éducation, statut marital
- Âge du client

📅 Historique de Paiement

- Variables PAY_0 à PAY_6
- Statut de remboursement mois par mois
- Retard de 1 à N mois

💰 Variables Financières

- Montants facturés BILL_AMT1–6
- Montants payés PAY_AMT1–6
- Écarts entre facturation et paiement

UNIVERSITÉ PARIS II
PANTHÉON-ASSAS

EXPLORATION

Analyse Exploratoire des Données

Déséquilibre des classes

Le dataset est **déséquilibré** : **78% de non-défaut** contre **22% de défaut**. Un modèle naïf prédisant toujours 0 atteindrait 78% d'accuracy sans détecter aucun défaut. D'où le recours à l'**AUC**, au **F1-score** et au **recall** plutôt qu'à l'accuracy seule.

Signaux prédictifs clés

- **PAY_X** : les plus informatives — taux de défaut de ~13% (à jour) à **+50%** (retard sévère)
- **LIMIT_BAL** : limites élevées = clients moins risqués, cohérent avec la logique bancaire
- **BILL_AMT** : forte corrélation entre variables, justifiant une sélection préalable

78%

Non-défaut

Classe majoritaire

22%

Défaut

Classe minoritaire à détecter

50%+

Taux de défaut

Pour retards sévères (PAY_X)

FEATURE ENGINEERING

UNIVERSITÉ PARIS II
PANTHÉON-ASSAS

Sélection des Variables : Lasso + Random Forest

Pour identifier les variables les plus pertinentes, deux approches complémentaires ont été combinées afin de capter à la fois les relations linéaires et non linéaires.

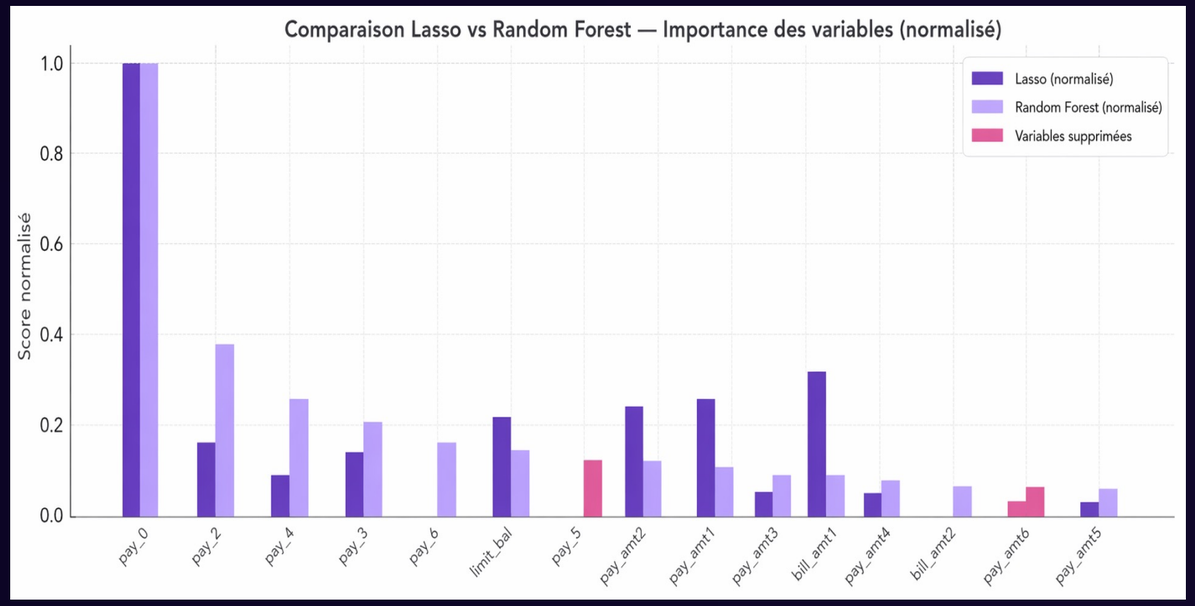

Régression Lasso (L1)

Pénalité L1 poussant certains coefficients vers zéro. Permet de **filtrer les variables peu utiles** dans un cadre linéaire et de réduire la dimensionnalité de façon interprétable.

Random Forest

Mesure l'importance des features via la **réduction d'impureté de Gini**. Capte des relations **non linéaires** que le Lasso ne détecte pas forcément.

ⓘ **Règle de sélection :** Conservation systématique des **5 variables de profil client** (limit_bal, sex, education, marriage, age), puis ajout des variables comportementales et financières jugées importantes par **au moins une des deux méthodes**. Résultat : **21 variables** retenues, avec PAY_0, PAY_2, PAY_3 et PAY_4 confirmés comme les plus prédictives.

MÉTHODOLOGIE

Protocole Expérimental

Split 80/20

Conserver ratio

Sélection 21

Entraînement

Évaluation

La séparation **80/20 avec stratify** garantit que la proportion de défauts (22%) est conservée dans les deux ensembles. L'évaluation sur un **jeu de test jamais vu** assure un cadre réaliste et évite tout biais d'optimisme. Le pipeline intègre la sélection de variables et la gestion du déséquilibre de façon cohérente et reproductible.

MODÉLISATION

Modèles Testés & Gestion du Déséquilibre

Quatre modèles ont été comparés, chacun avec une stratégie de gestion du déséquilibre adaptée à son fonctionnement propre.

Logistic Regression

`class_weight='balanced'` — augmente le poids de la classe minoritaire pendant l'entraînement.

Random Forest

`class_weight='balanced'` — même principe, appliqué aux arbres de décision.

XGBoost

`scale_pos_weight ≈ 3,52` — ratio natif entre négatifs et positifs, intégré directement dans l'algorithme de boosting.

MLP (Réseau de Neurones)

SMOTE appliqué **uniquement sur le train set** — sur-échantillonnage synthétique sans fuite d'information vers le test.

RÉSULTATS CV

Résultats de Cross-Validation Stratifiée (3 Folds)

	Model	CV AUC	CV AUC std	CV F1	CV Recall
0	XGBoost	0.7821	0.0069	0.5403	0.6306
1	Random Forest	0.7812	0.0040	0.5417	0.5638
2	Neural Network (MLP)	0.7377	0.0085	0.4894	0.5604
3	Logistic Regression	0.7263	0.0115	0.4794	0.6444

Interprétation

XGBoost et **Random Forest** dominent nettement en AUC (~0,78) et F1 (~0,54), confirmant la supériorité des approches non linéaires.

La **Logistic Regression** obtient le **meilleur recall** en validation croisée, récupérant davantage de défauts au prix d'une AUC plus faible.

Le **MLP** est en retrait, avec un AUC de 0,738, probablement en raison d'une complexité mal calibrée sur ce type de données tabulaires.

RÉSULTATS FINAUX

Performance sur le Jeu de Test

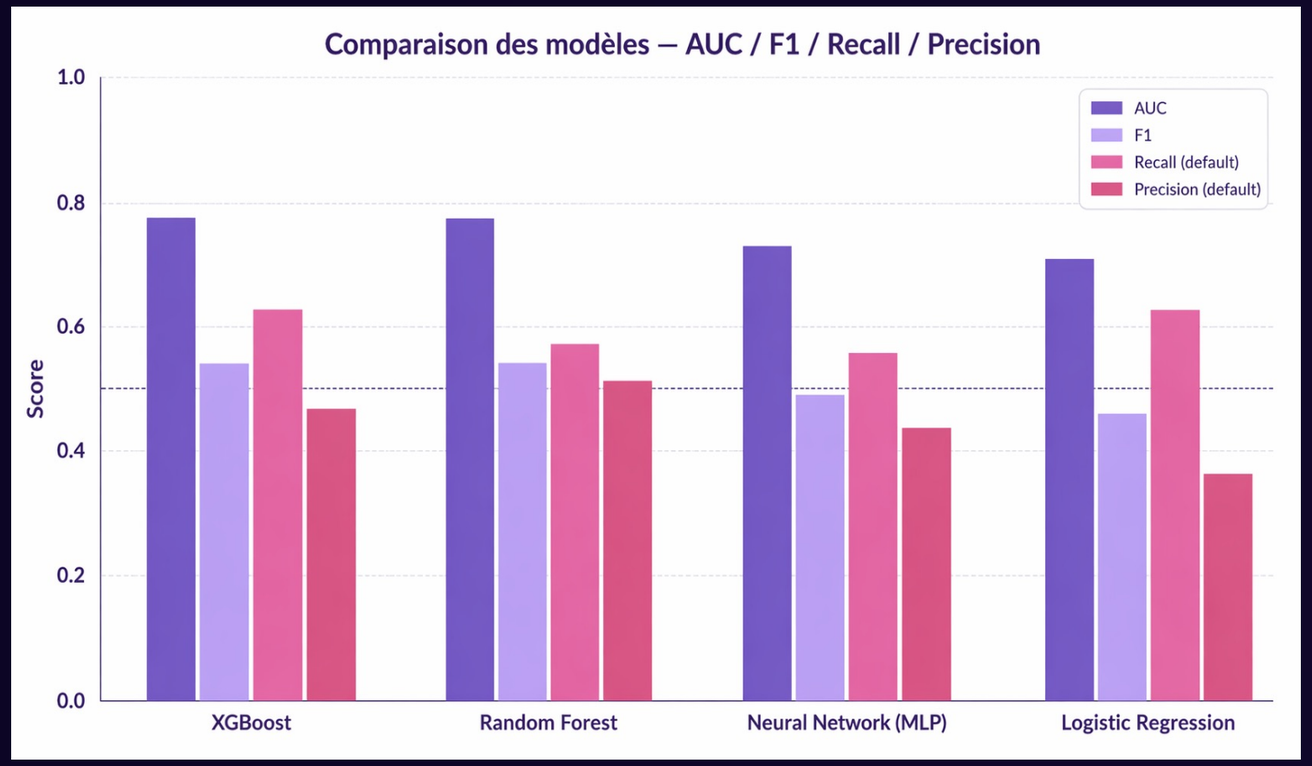

⚖️ Perspective Métier

Un **faux négatif** (client risqué non détecté) coûte souvent bien plus cher qu'un **faux positif** (client solvable refusé à tort).

Ainsi, un modèle avec un **recall élevé sur la classe défaut** peut devenir préférable, même s'il génère davantage de faux positifs..

🏆 Meilleurs scores par métrique

- **AUC** : XGBoost → **0,7765**
- **F1-Score** : Random Forest → **0,5393**
- **Précision** : Random Forest → **0,5133**
- **Recall** : Logistic Regression → **0,6209**

XGBoost excelle en séparation globale ; Random Forest offre le meilleur compromis précision/détection.

⚠️ Ne pas détecter un client réellement risqué a souvent un coût plus élevé que refuser à tort un client solvable.

DISCUSSION

UNIVERSITÉ PARIS II
PANTHÉON-ASSAS

Enseignements & Pistes d'Amélioration

Retard de paiement : signal dominant

Les variables **PAY_0 à PAY_4** sont identifiées comme les plus prédictives par le Lasso et le Random Forest. Le comportement passé de paiement reste le meilleur indicateur du comportement futur — cohérent avec l'intuition métier en risque de crédit.

LIMIT_BAL : cohérence économique

Une limite de crédit plus faible est associée à un risque plus élevé, ce qui reflète la logique bancaire : les plafonds élevés sont accordés aux clients jugés les plus solvables. Cette variable renforce la crédibilité métier du modèle.

Supériorité des modèles non linéaires

XGBoost et **Random Forest** surpassent la régression logistique, suggérant que les relations entre variables sont trop complexes pour être captées par un modèle purement linéaire.

🔭 Pistes d'Amélioration

- → **Feature engineering** enrichi : ratios d'utilisation du crédit, écarts facturés/payés, tendances temporelles
- → **Tuning des hyperparamètres** plus poussé (GridSearch, RandomizedSearch, Optuna)
- → **Optimisation du seuil de décision** selon un coût métier explicite entre faux négatifs et faux positifs
- → **Analyse SHAP** pour améliorer l'explicabilité des décisions à l'échelle individuelle

CONCLUSION

Conclusion & Perspectives

XGBoost — Meilleur AUC

0,7765 sur le test set. Meilleure capacité globale à distinguer les clients à risque. Idéal pour une vue d'ensemble du portefeuille.

Random Forest — Meilleur F1

0,5393 en F1-score, **0,5133** en précision. Compromis équilibré entre détection et fiabilité. Très intéressant opérationnellement.

Logistic Regression — Meilleur Recall

0,6209 en recall. Privilégiable si le coût des faux négatifs est très élevé et que la détection prime sur la précision.

À retenir : Le choix du modèle dépend non seulement de la performance statistique, mais surtout de la **fonction de coût métier** retenue. Les variables de **retard de paiement récent** et **LIMIT_BAL** confirment la cohérence économique du modèle. Prochaines étapes : feature engineering, tuning avancé, optimisation du seuil et analyse SHAP.